配置

模型配置

复制页面

了解 Claude Code 模型配置，包括模型别名（如 `opusplan` ）

可用模型

对于 Claude Code 中的 `model` 设置，您可以配置以下任一项：

- 一个**模型别名**
- 一个**模型名称**
  - Anthropic API：完整的**模型名称**
  - Bedrock：推理配置文件 ARN
  - Foundry：部署名称
  - Vertex：版本名称

模型别名

模型别名提供了一种便捷的方式来选择模型设置，无需记住确切的版本号：

模型别名	行为
`default`	推荐的模型设置，取决于您的账户类型
`sonnet`	使用最新的 Sonnet 模型（当前为 Sonnet 4.6）用于日常编码任务
`opus`	使用最新的 Opus 模型（当前为 Opus 4.6）用于复杂推理任务
`haiku`	使用快速高效的 Haiku 模型用于简单任务
`sonnet[1m]`	使用 Sonnet 和**100 万令牌上下文窗口**用于长会话
`opusplan`	特殊模式，在 Plan Mode 期间使用 `opus` ，然后在执行期间切换到 `sonnet`

Claude Code Docs

›

设置您的模型

您可以通过多种方式配置模型，按优先级顺序列出：

1. **在会话期间** - 使用 `/model <alias|name>` 在会话中间切换模型
2. **在启动时** - 使用 `claude --model <alias|name>` 启动
3. **环境变量** - 设置 `ANTHROPIC_MODEL=<alias|name>`
4. **设置** - 在设置文件中使用 `model` 字段永久配置。

使用示例：

```
# 使用 Opus 启动
claude --model opus

# 在会话期间切换到 Sonnet
/model sonnet
```

设置文件示例：

```
{
    "permissions": {
        ...
    },
    "model": "opus"
}
```

限制模型选择

企业管理员可以在 中使用 `availableModels` 来限制用户可以选择的模型。

设置 `availableModels` 后，用户无法通过 `/model` 、 `--model` 标志、Config 工具或 `ANTHROPIC_MODEL` 环境变量切换到列表中不包含的模型。

Claude Code Docs

›

默认模型行为

模型选择器中的"默认"选项不受 `availableModels` 影响。它始终保持可用，并代表系统的运行时默认值 。

即使使用 `availableModels: []` ，用户仍然可以使用其层级的默认模型来使用 Claude Code。

控制用户运行的模型

要完全控制模型体验，请将 `availableModels` 与 `model` 设置一起使用：

availableModels：限制用户可以切换到的内容

model：设置显式模型覆盖，优先于默认值

此示例确保所有用户运行 Sonnet 4.6，并且只能在 Sonnet 和 Haiku 之间选择：

```
{
  "model": "sonnet",
  "availableModels": ["sonnet", "haiku"]
}
```

合并行为

当 `availableModels` 在多个级别设置时（例如用户设置和项目设置），数组会被合并并去重。要强制执行严格的允许列表，请在托管或策略设置中设置 `availableModels` ，这具有最高优先级。

特殊模型行为

`default` 模型设置

Enterprise：Opus 4.6 可用但不是默认值

如果您使用 Opus 达到使用阈值，Claude Code 可能会自动回退到 Sonnet。

`opusplan` 模型设置

`opusplan` 模型别名提供了一种自动化的混合方法：

在 Plan Mode 中 - 使用 `opus` 进行复杂推理和架构决策

在执行模式中 - 自动切换到 `sonnet` 进行代码生成和实现

这为您提供了两全其美的方案：Opus 的卓越推理能力用于规划，Sonnet 的效率用于执行。

调整工作量级别

工作量级别控制 Opus 4.6 的自适应推理，它根据任务复杂性动态分配思考。较低的工作量对于直接任务更快且更便宜，而较高的工作量为复杂问题提供更深入的推理。

有三个级别可用：**low**、**medium** 和 **high**（默认）。

设置工作量：

在 `/model` 中：选择模型时使用左右箭头键调整工作量滑块

环境变量：设置 `CLAUDE_CODE_EFFORT_LEVEL=low|medium|high`

设置：在设置文件中设置 `effortLevel`

工作量目前在 Opus 4.6 上受支持。当选择受支持的模型时，工作量滑块会出现在 `/model` 中。

要禁用 Opus 4.6 和 Sonnet 4.6 上的自适应推理并恢复到之前的固定思考预算，请设置 `CLAUDE_CODE_DISABLE_ADAPTIVE_THINKING=1` 。禁用时，这些模型使用由 `MAX_THINKING_TOKENS` 控制的固定预算。请参阅**环境变量**。

扩展上下文

Claude Code Docs

›

扩展上下文可用于：

- **API 和按使用量付费用户**：完全访问 100 万令牌上下文
- **Pro、Max、Teams 和 Enterprise 订阅者**：可通过**额外使用**获得

要完全禁用 100 万令牌上下文，请设置 `CLAUDE_CODE_DISABLE_1M_CONTEXT=1` 。这会从模型选择器中删除 100 万令牌模型变体。请参阅**环境变量**。

选择 100 万令牌模型不会立即改变计费。您的会话使用标准费率，直到超过 200K 令牌的上下文。超过 200K 令牌后，请求按**长上下文定价**收费，并具有专用**速率限制**。对于订阅者，超过 200K 的令牌作为额外使用而不是通过订阅计费。

如果您的账户支持 100 万令牌上下文，该选项会在最新版本的 Claude Code 中的模型选择器（ `/model` ）中出现。如果您看不到它，请尝试重新启动您的会话。

您也可以将 `[1m]` 后缀与模型别名或完整模型名称一起使用：

```
# 使用 sonnet[1m] 别名
/model sonnet[1m]

# 或将 [1m] 附加到完整模型名称
/model claude-sonnet-4-6[1m]
```

检查您当前的模型

您可以通过多种方式查看您当前使用的模型：

1. 在 中（如果已配置）
2. 在 `/status` 中，它也显示您的账户信息。

环境变量

Claude Code Docs

›

`ANTHROPIC_DEFAULT_OPUS_MODEL`	用于 `opus` 的模型，或在 Plan Mode 活跃时用于 `opusplan` 的模型。
`ANTHROPIC_DEFAULT_SONNET_MODEL`	用于 `sonnet` 的模型，或在 Plan Mode 不活跃时用于 `opusplan` 的模型。
`ANTHROPIC_DEFAULT_HAIKU_MODEL`	用于 `haiku` 的模型，或**后台功能**
`CLAUDE_CODE_SUBAGENT_MODEL`	用于**subagents**的模型

注意： `ANTHROPIC_SMALL_FAST_MODEL` 已弃用，改为使用 `ANTHROPIC_DEFAULT_HAIKU_MODEL` 。

为第三方部署固定模型

通过 **Bedrock**、**Vertex AI** 或 **Foundry** 部署 Claude Code 时，在向用户推出前固定模型版本。

不固定模型时，Claude Code 使用模型别名（ `sonnet` 、 `opus` 、 `haiku` ），这些别名解析为最新版本。当 Anthropic 发布新模型时，其账户未启用新版本的用户将无声地中断。

> ⚠ 在初始设置中将所有三个模型环境变量设置为特定版本 ID。跳过此步骤意味着 Claude Code 更新可能会在您没有任何操作的情况下破坏您的用户。

对您的提供商使用以下环境变量和特定版本的模型 ID：

提供商	示例
Bedrock	`export ANTHROPIC_DEFAULT_OPUS_MODEL='us.anthropic.claude-opus-4-6-v1'`
Vertex AI	`export ANTHROPIC_DEFAULT_OPUS_MODEL='claude-opus-4-6'`
Foundry	`export ANTHROPIC_DEFAULT_OPUS_MODEL='claude-opus-4-6'`

对 `ANTHROPIC_DEFAULT_SONNET_MODEL` 和 `ANTHROPIC_DEFAULT_HAIKU_MODEL` 应用相同的模式。有关所有提供商的当前和旧版模型 ID，请参阅**模型概览**。要将用户升级到新模型版本，请更

Prompt caching 配置

Claude Code 自动使用 **prompt caching** 来优化性能并降低成本。您可以全局禁用 prompt caching 或针对特定模型层级禁用：

环境变量	描述
`DISABLE_PROMPT_CACHING`	设置为 `1` 以禁用所有模型的 prompt caching（优先于按模型设置）
`DISABLE_PROMPT_CACHING_HAIKU`	设置为 `1` 以仅禁用 Haiku 模型的 prompt caching
`DISABLE_PROMPT_CACHING_SONNET`	设置为 `1` 以仅禁用 Sonnet 模型的 prompt caching
`DISABLE_PROMPT_CACHING_OPUS`	设置为 `1` 以仅禁用 Opus 模型的 prompt caching

这些环境变量为您提供了对 prompt caching 行为的细粒度控制。全局 `DISABLE_PROMPT_CACHING` 设置优先于特定模型设置，允许您在需要时快速禁用所有缓存。按模型设置对于选择性控制很有用，例如在调试特定模型或使用可能具有不同缓存实现的云提供商时。

此页面对您有帮助吗？ 是 否

‹ 终端配置 使用快速模式加快响应速度 ›

Claude Code Docs

Trust center

Transparency

Learn

Courses

MCP connectors

Customer stories

Engineering blog

Events

Powered by Claude

Service partners

Startups program

Terms and policies

Privacy policy

Disclosure policy

Usage policy

Commercial terms

Consumer terms